

# Számítási modellek

## 1. előadás

# Számítási modellek – a kezdetek

- ▶ Alex Thue 1910-es évek, sztringek algebrai, kombinatorikai tulajdonságai  $\mapsto$  a sztringeket átíró *szabályrendszer*
- ▶ Alan Turing és kortársai 1930-as évek közepe: Turing gép, kiszámíthatóság; első számítási modellek (matematikai gépek) és kifejező erejük
- ▶ 40-es évek: véges automata formalizálása, 50-es évek vége: veremautomata formalizálása
- ▶ Noam Chomsky 1950-es évek a formális grammatika fogalma
- ▶ 1950-es évek: Backus-Naur Forma
- ▶ gépi fordítási projektek, matematikai nyelvészethez kapcsolódó munkák, 1950-es 60-as évek
- ▶ Rabin és Scott: formális eszközök kifejlesztése számítási modellek kifejezőerejének és korlátainak vizsgálatára
- ▶ Chomsky-féle nyelvhierarchia, 1956-64
- ▶ 60-as évek: időigény, tárigény, bonyolultsági osztályok, NP-teljesség
- ▶ új, nemkonvencionális modellek

# Alapfogalmak, jelölések

ábécé, betű, szó, szó hossza

**Ábécé:** Egy véges, nemüres halmaz.  
Az ábécé elemeit **betűk**nek nevezzük.

Egy  $V$  ábécé elemeiből képzett véges sorozatokat  **$V$  feletti szavaknak** vagy sztringeknek nevezzük. Egy  $u = t_1 \cdot \dots \cdot t_n$  szóban lévő betűk számát ( $n$ ) a szó **hosszának** nevezzük. Jelölés:  $|u| = n$ . A 0 hosszú sorozat jelölése  $\varepsilon$ , ezt **üres szónak** nevezzük ( $|\varepsilon| = 0$ ).

## Példa:

Legyen  $V = \{a, b\}$ , ekkor  $a$  és  $b$  a  $V$  ábécé két betűje.  $abba$  és  $aabba$  egy-egy  $V$  feletti szó.  $|aabba| = 5$ .  $aabba$  és  $baaba$  különböző szavak, bár mindkettő 5 hosszú valamint 3  $a$ -t és 2  $b$ -t tartalmaz. A betűk sorrendje számít!

# Alapfogalmak, jelölések

az összes szavak halmaza

$V^*$  jelöli a  $V$  ábécé feletti szavak halmazát, beleértve az üres szót is.

$V^+ = V^* \setminus \{\varepsilon\}$  a  $V$  ábécé feletti, nemüres szavak halmazát jelöli.

**Példa:**  $V = \{a, b\}$ , ekkor

$V^* = \{\varepsilon, a, b, aa, ab, ba, bb, aaa, aab, \dots\}$ .

$V^*$  szavainak egy lehetséges felsorolása a **hosszlexikografikus (shortlex) rendezés** szerinti:

- Feltesszük, hogy az ábécé rendezett. (A fenti példában, mondjuk  $a$  előbb van, mint  $b$ .)
- A rövidebb szó mindig megelőzi a hosszabbat.
- Az azonos hosszúságú szavak az ábécé rendezettsége alapján meghatározott ábécésorrendben követik egymást.

Ez a rendezés egyértelműen meghatározza a szavak sorrendjét.

# Műveletek szavakon

## konkatenáció

Legyen  $V$  egy ábécé továbbá legyenek  $u = s_1 \cdots s_n$  és  $v = t_1 \cdots t_k$   $V$  feletti szavak (azaz legyen  $s_1, \dots, s_n, t_1, \dots, t_k \in V$ ). Ekkor az  $uv := s_1 \cdots s_n t_1 \cdots t_k$  szót az  $u$  és  $v$  szavak **konkatenáltjának** nevezzük. (Az  $u$  szó betűi után írjuk a  $v$  szó betűit.)

Nyilván  $|uv| = |u| + |v|$ .

### Példa:

Legyen  $V = \{a, b\}$ , valamint  $u = abb$  és  $v = aaaba$  egy-egy  $V$  feletti szó. Ekkor  $uv = abbaaaba$  illetve  $vu = aaabaabb$ .

Azaz a konkatenáció **általában nem kommutatív**, de asszociatív (azaz  $u(vw) = (uv)w$  teljesül minden  $u, v, w \in V^*$ -ra )

# Műveletek szavakon

## $i$ -edik hatvány

Legyen  $i$  nemnegatív egész szám és legyen  $u$  egy  $V$  ábécé feletti szó ( $u \in V^*$ ). Az  $u$  szó  $i$ -edik hatványa alatt az  $u$  szó  $i$  darab példányának konkatenáltját értjük és  $u^i$  -vel jelöljük.

Konvenció szerint  $u^0 := \varepsilon$ . Ekkor  $u^{n+k} = u^n u^k$  teljesül ( $k, n \in \mathbb{N}$ )

## Példa:

Legyen  $V = \{a, b\}$  és legyen  $u = abb$ . Ekkor  $u^0 = \varepsilon$ ,  $u^1 = abb$ ,  $u^2 = abbabb$  és  $u^3 = abbabbabb$ .

$$(ab)^3 \neq a^3 b^3 \quad ! ! ! !$$

$$(ab)^3 = ababab, \quad a^3 b^3 = aaabbb.$$

# Műveletek szavakon

## tükörkép

Legyen  $u$  egy  $V$  ábécé feletti szó. Az  $u$  szó  $u^{-1}$ -gyel jelölt **tükörképén** vagy fordítottján azt a szót értjük, amelyet úgy kapunk, hogy  $u$  betűit fordított sorrendben írjuk le.

Azaz ha  $u = a_1 \cdots a_n$ ,  $a_i \in V$ ,  $1 \leq i \leq n$ , akkor  $u^{-1} = a_n \cdots a_1$ .

## Példa:

Legyen  $V = \{a, b\}$ , valamint  $u = abba$  és  $v = baabba$  egy-egy  $V$  ábécé feletti szó. Ekkor  $u^{-1} = abba$  és  $v^{-1} = abbaab$ .

Ha  $u = u^{-1}$ , akkor  $u$ -t **palindrom** tulajdonságúnak, vagy palindrómának nevezzük.

Tehát  $abba$  egy palindróma.

# Alapfogalmak, jelölések

részszó, prefix, suffix

Legyen  $V$  egy ábécé és legyenek  $u$  és  $v$  szavak  $V$  felett. Az  $u$  szó a  $v$  szó **részszava**, ha  $v = xuy$  teljesül, valamely  $x, y \in V^*$  szavakra.

Ha  $x = \varepsilon$ , akkor  $u$ -t a  $v$  szó **prefixének**, ha pedig  $y = \varepsilon$ , akkor  $u$ -t a  $v$  szó **suffixének** nevezzük.

## Példa:

Legyen  $V = \{a, b\}$  és  $u = abba$ .

$u$  részszavai:  $\varepsilon, a, b, ab, bb, ba, abb, bba, abba$ .

$u$  prefixei:  $\varepsilon, a, ab, abb, abba$ .

$u$  suffixei:  $\varepsilon, a, ba, bba, abba$ .

**$abb$  nem suffixe  $u$ -nak!!!** A suffix nem a tükörkép szó prefixe!!!



# Alapfogalmak, jelölések

## nyelv

Legyen  $V$  egy ábécé,  $V^*$  egy  $L$  részhalmazát  $V$  feletti **nyelvnek** nevezzük.

Az üres nyelv (nyelv, amely egyetlen szót sem tartalmaz) jelölése  $\emptyset$ .

Egy  $V$  ábécé feletti nyelv véges nyelv, ha véges számú szót tartalmaz, ellenkező esetben végtelen.

## Példák:

Legyen  $V = \{a, b\}$  egy ábécé.

- ▶  $L_1 = \{a, ba, \varepsilon\}$ .
- ▶  $L_2 = \{a^i b^i \mid i \geq 0\}$ .
- ▶  $L_3 = \{uu^{-1} \mid u \in V^*\}$ .
- ▶  $L_4 = \{u \mid u \in \{a, b\}^+, u\text{-ban ugyanannyi } a \text{ van, mint } b\}$ .

$L_1$  véges nyelv, a többi végtelen.

# Nyelvekre vonatkozó műveletek

## halmazműveletek

Legyen  $V$  egy ábécé és legyenek  $L_1, L_2$  nyelvek  $V$  felett (vagyis  $L_1 \subseteq V^*$  és  $L_2 \subseteq V^*$  ).

$L_1 \cup L_2 = \{u \mid u \in L_1 \text{ vagy } u \in L_2\}$  (az  $L_1$  és az  $L_2$  nyelv **uniója**)

$L_1 \cap L_2 = \{u \mid u \in L_1 \text{ és } u \in L_2\}$  (az  $L_1$  és  $L_2$  nyelv **meteszete**)

$L_1 - L_2 = \{u \mid u \in L_1 \text{ és } u \notin L_2\}$  (az  $L_1$  és az  $L_2$  nyelv **különbsége**)

Az  $L \subseteq V^*$  nyelv **komplementere** a  $V$  ábécére nézve az  $\bar{L} = V^* - L$  nyelv.

# Nyelvekre vonatkozó műveletek

## konkatenáció

Legyen  $V$  egy ábécé és  $L_1, L_2 \subseteq V^*$ . Az  $L_1$  és az  $L_2$  nyelvek **konkatenációján** az  $L_1 L_2 = \{u_1 u_2 \mid u_1 \in L_1, u_2 \in L_2\}$  nyelvet értjük. Asszociatív, de nyilván **nem kommutatív** művelet.

### Példák:

$$V = \{a, b\}, L_1 = \{ab, bb\}, L_2 = \{\varepsilon, a, bba\},$$

$$\begin{aligned} L_1 L_2 &= \{ab\varepsilon, bb\varepsilon, aba, bba, abbba, bbbba\} \\ &= \{ab, bb, aba, bba, abbba, bbbba\}. \end{aligned} \quad (\text{mindenkit mindenkivel!})$$

$$L_3 = \{a^{2n} b^{2n} \mid n \in \mathbb{N}\}, L_4 = \{a^{3n} b^{3n} \mid n \in \mathbb{N}\}$$

$$L_3 L_4 = \{a^{2n} b^{2n} a^{3k} b^{3k} \mid n, k \in \mathbb{N}\}.$$

# Nyelvekre vonatkozó műveletek

## tükörkép nyelv, $i$ -edik hatvány

Legyen  $V$  egy ábécé és legyen  $L \subseteq V^*$ . Ekkor  $L^{-1} = \{u^{-1} \mid u \in L\}$  a **tükörképe** (megfordítása) az  $L$  nyelvnek.

Egy  $L$  nyelv  **$i$ -edik hatványát**  $L^0 := \{\varepsilon\}$  és  $L^i := LL^{i-1}$  ( $i \geq 1$ ) definiálják. Azaz  $L^i$  jelöli az  $L$   $i$ -edik iterációját a konkatenáció műveletére nézve.

**Példa:**  $L = \{a, bb\}$ .

$$L^0 = \{\varepsilon\},$$

$$L^1 = \{a, bb\},$$

$$L^2 = \{aa, abb, bba, bb bb\},$$

$$L^3 = \{aaa, aabb, abb a, abbb, bb aa, bba bb, bbba, bb bb bb\},$$

# Nyelvekre vonatkozó műveletek

## Kleene lezárt

Az  $L$  nyelv **iteratív lezártja** (vagy röviden lezártja vagy Kleene-lezártja) alatt az  $L^* = \bigcup_{i \geq 0} L^i$  nyelvet értjük.

Az  $L$  nyelv **pozitív lezártja** alatt az  $L^+ = \bigcup_{i \geq 1} L^i$  nyelvet értjük.

## Észrevétel:

Nyilvánvalóan,  $L^+ = L^*$ , ha  $\varepsilon \in L$  és  $L^+ = L^* - \{\varepsilon\}$  ha  $\varepsilon \notin L$ .

**Példa:**  $L = \{a, bb\}$ .

$$L^0 = \{\varepsilon\},$$

$$L^1 = \{a, bb\},$$

$$L^2 = \{aa, abb, bba, bb bb\},$$

$$L^3 = \{aaa, aabb, abb a, abbb, bbaa, bba bb, bbba, bb bb bb\},$$

$$L^4 = \{aaaa, aaaa bb, aaabba, \dots\}, \dots$$

Ezen szavak uniója együttesen alkotja  $L^*$ -t.  $L^+$  ettől csak annyiban tér el, hogy nincs benne az  $\varepsilon$  szó.

# Nyelvcsaládok

Ha  $X$  egy halmaz, jelölje  $\mathcal{P}(X)$  az  $X$  halmaz hatványhalmazát, azaz  $\mathcal{P}(X) = \{A \mid A \subseteq X\}$ .

**Nyelvcsalád** (vagy nyelvosztály) alatt nyelveknek egy halmazát értjük.

Tehát ha  $V$  egy ábécé:

- $a \in V$ : betű
- $u \in V^*$ : szó
- $L \subseteq V^*$  vagy  $L \in \mathcal{P}(V^*)$ : nyelv
- $\mathcal{L} \subseteq \mathcal{P}(V^*)$  vagy  $\mathcal{L} \in \mathcal{P}(\mathcal{P}(V^*))$ : nyelvcsalád

**Példa:**  $V = \{a, b\}$

- véges nyelvek nyelvcsaládja
- csak  $b$  betűvel kezdődő szavakat tartalmazó nyelvek nyelvcsaládja
- reguláris kifejezésekkel leírható nyelvek nyelvcsaládja

# Grammatikák

## Definíció

Egy  $G = \langle N, T, P, S \rangle$  rendezett négyest **grammatikának** (generatív grammatikán vagy (generatív) nyelvtannak) nevezünk ha

- ▶  $N$  és  $T$  diszjunkt véges ábécék (azaz  $N \cap T = \emptyset$ ).  $N$  elemeit **nemterminális**,  $T$  elemeit pedig **terminális** szimbólumoknak nevezzük.
- ▶  $S \in N$  a grammatika **kezdőszimbóluma**.
- ▶  $P$  rendezett  $(x, y)$  párok véges halmaza, ahol  $x, y \in (N \cup T)^*$  és  $x$  legalább egy nemterminális szimbólumot tartalmaz.

A  $P$  halmaz elemeit **szabályoknak** (vagy átírási szabályoknak vagy produkcióknak) hívjuk. A gyakorlatban az  $(x, y)$  jelölés helyett szinte mindig az  $x \rightarrow y$  jelölést használjuk amennyiben  $\rightarrow$  nem eleme  $N \cup T$ -nek.

# Grammatikák

## Példák:

$G_1 = \langle \{S, A, B\}, \{a, b, c\}, \{S \rightarrow c, S \rightarrow AB, A \rightarrow aA, B \rightarrow \varepsilon, abb \rightarrow aSb\}, S \rangle$  **nem** grammatika, mivel minden szabály baloldalának tartalmaznia kell legalább egy  $N$ -beli szimbólumot.

$G_2 = \langle \{S, A, B, C\}, \{a, b, c\}, \{S \rightarrow a, S \rightarrow AB, A \rightarrow Ab, B \rightarrow \varepsilon, aCA \rightarrow aSc\}, S \rangle$  grammatika.



# Generatív grammatikák

## egylépéses levezetés

### Definíció

Legyen  $G = \langle N, T, P, S \rangle$  egy generatív grammatika és legyen  $u, v \in (N \cup T)^*$ . A  $v$  szó közvetlenül vagy **egy lépésben levezethető** az  $u$  szóból  $G$ -ben, jelölése  $u \Rightarrow_G v$ , ha  $u = u_1xu_2$  és  $v = u_1yu_2$ , ahol  $u_1, u_2 \in (N \cup T)^*$  és  $x \rightarrow y \in P$ .

### Példa:

$G_2 = \langle \{S, A, B, C\}, \{a, b, c\}, \{S \rightarrow a, S \rightarrow AB, A \rightarrow Ab, B \rightarrow \varepsilon, aCA \rightarrow aSc\}, S \rangle$ .

Ekkor  $BBaCAa \Rightarrow BBaSc a$ ,  $ABB \Rightarrow AbBB$ ,  $BB \Rightarrow B$ .

# Reláció reflexív, tranzitív lezártja

- ▶ Legyenek  $X_1, \dots, X_n$  halmazok és  $R \subseteq X_1 \times \dots \times X_n$ , ekkor  $R$ -et  **$n$ -változós relációnak** nevezzük.
- ▶  $R \subseteq X \times Y$  és  $S \subseteq Y \times Z$  bináris relációk **kompozíciója**  
 $R \circ S = \{(x, z) \in X \times Z \mid \exists y \in Y : (x, y) \in R \wedge (y, z) \in S\}$
- ▶  $R^1 := R$ ,  $R^i := R \circ R^{i-1}$  ( $i \geq 2$ ) definiálja  $R$   **$i$ -edik hatványát**
- ▶ Ha  $R \subseteq X \times X$ , akkor  $S := R \cup \{(x, x) \mid x \in X\}$  az  $R$  reláció **reflexív lezártja**
- ▶ Ha  $R \subseteq X \times X$ , akkor  $R^+ := \bigcup_{i=1,2,\dots} R^i$  az  $R$  reláció **tranzitív lezártja**
- ▶ Ha  $R \subseteq X \times X$ , akkor  $R^* := R^+ \cup \{(x, x) \mid x \in X\}$  az  $R$  reláció **reflexív, tranzitív lezártja**

# Reláció reflexív, tranzitív lezártja

## Példa:

$X = \{1, 2, 3, 4, 5\}$ ,  $R = \{(1, 2), (2, 3), (3, 4), (2, 5)\}$  ekkor

$S = \{(1, 2), (2, 3), (3, 4), (2, 5), (1, 1), (2, 2), (3, 3), (4, 4), (5, 5)\}$  az  $R$  reflexív lezártja

$$R^1 = R = \{(1, 2), (2, 3), (3, 4), (2, 5)\}$$

$$R^2 = \{(1, 3), (2, 4), (1, 5)\}$$

$$R^3 = \{(1, 4)\}$$

$$R^4 = R^5 = \dots = \emptyset$$

$R^+ = \{(1, 2), (2, 3), (3, 4), (2, 5), (1, 3), (2, 4), (1, 5), (1, 4)\}$  az  $R$  tranzitív lezártja

$R^* = \{(1, 2), (2, 3), (3, 4), (2, 5), (1, 3), (2, 4), (1, 5), (1, 4), (1, 1), (2, 2), (3, 3), (4, 4), (5, 5)\}$  az  $R$  reflexív, tranzitív lezártja

# Reláció reflexív, tranzitív lezártja

## Észrevételek:

- ▶ A bináris relációk éppen az irányított gráfok (a reláció elemei megfeleltethetők az irányított éleknek).
- ▶ A bináris relációk reflexív, tranzitív lezártja egy olyan gráfnak felel meg, melyben  $u$ -ból  $v$ -be pontosan akkor van él, ha az eredeti gráfban van (véges) irányított út.
- ▶  $\Rightarrow_G$  egy bináris reláció a végtelen  $X = (N \cup T)^*$  halmaz felett.
- ▶  $A \Rightarrow_G$  egylépéses levezetés reláció tehát természetes módon megad egy végtelen irányított gráfot az  $(N \cup T)^*$  csúcshalmazon.
- ▶  $A \Rightarrow_G^*$  reflexív tranzitív lezárt gráfban  $u$ -ból  $v$ -be pontosan akkor van irányított él, ha véges sok egylépéses levezetésen át el lehet jutni  $u$ -ból  $v$ -be

# Grammatikák

## többlépéses levezetés

### Definíció

Legyen  $G = \langle N, T, P, S \rangle$  egy grammatika és legyen  $u, v \in (N \cup T)^*$ .  $u$ -ból (több lépésben) **levezethető**  $v$ , ha  $(u, v) \in \Rightarrow_G^*$ . ( $\Rightarrow_G^*$  a  $\Rightarrow_G$  reflexív tranzitív lezártja)

$u$ -ból  **$k$  lépésben levezethető**  $v$ , ha  $(u, v) \in \Rightarrow_G^k$ . ( $\Rightarrow_G^k$  a  $\Rightarrow_G$   $k$ -adik hatványa).

A kezdőszimbólumból levezethető szavakat **mondatformának** nevezzük.

Megadunk egy alternatív, közvetlen definíciót is:

### Definíció

Legyen  $G = \langle N, T, P, S \rangle$  egy grammatika és legyen  $u, v \in (N \cup T)^*$ .  $u$ -ból (több lépésben) **levezethető**  $v$ , ha  $u = v$  vagy van olyan  $n \geq 1$  és  $w_0, \dots, w_n \in (N \cup T)^*$ , hogy  $w_{i-1} \Rightarrow_G w_i$  ( $1 \leq i \leq n$ ) és  $w_0 = u$  és  $w_n = v$ . Jelölés:  $u \Rightarrow_G^* v$ .

# Grammatikák

## többlépéses levezetés

Ha egyértelmű melyik nyelvtanról van szó, akkor  $\Rightarrow_G$  helyett röviden  $\Rightarrow$ -t írhatunk.

### Példa:

$$G_2 = \langle \{S, A, B, C\}, \{a, b, c\}, \{S \rightarrow a, S \rightarrow AB, A \rightarrow Ab, B \rightarrow \varepsilon, aCA \rightarrow aSc\}, S \rangle.$$

Ekkor  $BBaCAa \Rightarrow BBaSc a$  és  $BBaSc a \Rightarrow BBaABca$ , tehát  $BBaCAa \Rightarrow^* BBaABca$ .

$S \Rightarrow AB \Rightarrow AbB \Rightarrow AbbB$ , tehát  $AbbB$  egy mondatforma.

# Generált nyelv

## Definíció

Legyen  $G = \langle N, T, P, S \rangle$  egy tetszőleges generatív grammatika. A  $G$  grammatika által **generált**  $L(G)$  **nyelv** alatt az  $L(G) = \{w \mid S \Rightarrow_G^* w, w \in T^*\}$  szavakból álló halmazt értjük.

## Példák:

- ▶  $G = \langle N, T, P, S \rangle$ , ahol  $N = \{S, A, B\}$ ,  $T = \{a, b\}$  és  $P = \{S \rightarrow aSb, S \rightarrow ab, S \rightarrow ba\}$ .

Ekkor  $L(G) = \{a^n abb^n, a^n bab^n \mid n \geq 0\}$ .

- ▶  $G_1 = \langle N, T, P, S \rangle$ , ahol  $N = \{S, A, B\}$ ,  $T = \{a, b\}$  és  $P = \{S \rightarrow ASB, S \rightarrow \varepsilon, AB \rightarrow BA, BA \rightarrow AB, A \rightarrow a, B \rightarrow b\}$ .

Ekkor  $L(G_1) = \{u \in \{a, b\}^* \mid u\text{-ban ugyanannyi } a \text{ van, mint } b\}$ .

# Ekvivalens grammatikák

Minden grammatika generál egy nyelvet, de ugyanazt a nyelvet több különböző grammatika is generálhatja.

Két **grammatika ekvivalens**, ha ugyanazt a nyelvet generálják.

**Példa:**

$G_2 = \langle N, T, P, S \rangle$ , ahol  $N = \{S, A, B\}$ ,  $T = \{a, b\}$  és  $P = \{S \rightarrow SS, S \rightarrow aSb, S \rightarrow bSa, S \rightarrow \varepsilon\}$ .

Belátható, hogy

$L(G_2) = \{u \in \{a, b\}^* \mid u\text{-ban ugyanannyi } a \text{ van, mint } b\}$ . Így ez a grammatika ekvivalens az előzővel.



# Grammatikák Chomsky féle osztályozása

Legyen  $G = \langle N, T, P, S \rangle$  egy generatív grammatika. A  $G$  generatív grammatika  $i$ -típusú ( $i = 0, 1, 2, 3$ ), ha  $P$  szabályhalmazára teljesülnek a következők:

- ▶  $i = 0$ : nincs korlátozás,
- ▶  $i = 1$ :  $P$  minden szabálya  $u_1Au_2 \rightarrow u_1vu_2$  alakú, ahol  $u_1, u_2, v \in (N \cup T)^*$ ,  $A \in N$ , és  $v \neq \varepsilon$ , kivéve az  $S \rightarrow \varepsilon$  alakú szabályt, feltéve, hogy  $P$ -ben ilyen szabály létezik. Ha  $P$  tartalmazza az  $S \rightarrow \varepsilon$  szabályt, akkor  $S$  nem fordul elő  $P$  egyetlen szabályának jobb oldalán sem,
- ▶  $i = 2$ :  $P$  minden szabálya  $A \rightarrow v$  alakú, ahol  $A \in N$  és  $v \in (N \cup T)^*$ ,
- ▶  $i = 3$ :  $P$  minden szabálya vagy  $A \rightarrow uB$  vagy  $A \rightarrow u$ , alakú, ahol  $A, B \in N$  és  $u \in T^*$ .

# Grammatikaosztályba sorolás

**Példa:** Legyen  $G = \langle N, T, P, S \rangle$ , ahol  $N = \{S, A, B\}$ ,  $T = \{a, b\}$  és  $P = \{S \rightarrow ASB, S \rightarrow \varepsilon, AB \rightarrow BA, BA \rightarrow AB, A \rightarrow a, B \rightarrow b\}$ . Szabályról szabályra nézzük meg, hogy az adott szabály melyik típusba engedi sorolni a grammatikát.

$S \rightarrow ASB$       0, 1, 2

$S \rightarrow \varepsilon$       0, 1, 2, 3

$AB \rightarrow BA$       0

$BA \rightarrow AB$       0

$A \rightarrow a$       0, 1, 2, 3

$B \rightarrow b$       0, 1, 2, 3

Az első 2 szabály nem lehet együtt 1-típusú grammatikában.

A 3. és 4. szabály a 0-son kívül mindent kizár, így a grammatika csak a 0-típusba skatulyázható.

# Nyelvek Chomsky féle osztályozása

**Noam Chomsky** (1928–) amerikai nyelvész, filozófus, politikai aktivista. A generatív nyelvtan elméletének megalkotója, kidolgozója a róla elnevezett Chomsky-hierarchiának. (Wikipédia)



Egy  $L$  nyelvet  **$i$ -típusúnak** mondunk, ahol  $i = 0, 1, 2, 3$ , ha  $i$ -típusú grammatikával generálható.  $\mathcal{L}_i$  ( $i = 0, 1, 2, 3$ ) jelöli az  $i$ -típusú nyelvek nyelvosztályát.

**Példa:** A korábbi 0-típusú  $G_1$  és 2-típusú  $G_2$  grammatikák egyaránt  $L = \{u \in \{a, b\}^* \mid u\text{-ban ugyanannyi } a \text{ van, mint } b\}$ -t generálják, így  $L \in \mathcal{L}_2$ .

# A Chomsky féle grammatikaosztályok elnevezése

- ▶ A 0-típusú grammatikákat **mondatszerkezetű** (phrase-structure) grammatikáknak is nevezzük, ami nyelvészeti eredetükre utal.
- ▶ A 1-típusú grammatikák a **környezetfüggő** (context-sensitive) grammatikák, mert szabályai olyanok, hogy, egy  $A$  nemterminális valamely előfordulása egy  $v$  szóval csak  $u_1$  és  $u_2$  kontextus jelenlétében helyettesíthető.
- ▶ 2-típusú grammatikákat **környezetfüggetlen** (context-free) grammatikáknak mondjuk, mert szabályai olyanok, hogy az  $A$  nemterminális  $v$ -vel való helyettesítése bármely kontextusban megengedett.
- ▶ A 3-típusú grammatikákat **reguláris** (regular) vagy véges állapotú (finite state) grammatikáknak hívjuk, a véges állapotú automatókkal való kapcsolatuk miatt.

A 0,1,2,3-típusú nyelvek osztályait rendre **rekurzíven felsorolható**, **környezetfüggő**, **környezetfüggetlen**, valamint **reguláris** nyelvosztálynak is mondjuk.

# A Chomsky-féle hierarchia

A grammatikák alakjából nyilvánvaló, hogy  $\mathcal{L}_3 \subseteq \mathcal{L}_2 \subseteq \mathcal{L}_0$  és  $\mathcal{L}_1 \subseteq \mathcal{L}_0$ .

## Tétel (Chomsky-féle nyelvhierarchia)

$$\mathcal{L}_3 \subset \mathcal{L}_2 \subset \mathcal{L}_1 \subset \mathcal{L}_0.$$

Itt az  $\mathcal{L}_2$  és az  $\mathcal{L}_1$  nyelvosztályok közötti tartalmazási reláció nem látható azonnal a megfelelő grammatikák definíciójából.

Szintén  $\mathcal{L}_1$ -et tudják generálni a **hossznemcsökkentő** grammatikák. Ezek  $p \rightarrow q$  szabályaira  $|p| \leq |q|$  teljesül kivéve az  $S \rightarrow \varepsilon$  alakú szabályt, feltéve, hogy  $P$ -ben ilyen szabály létezik. Ha  $P$  tartalmazza az  $S \rightarrow \varepsilon$  szabályt, akkor  $S$  nem fordul elő  $P$  egyetlen szabályának jobb oldalán sem.

# Grammatikák a gyakorlatban

BNF (Backus-Naur Form) **John Backus, Peter Naur ALGOL 60**

A BNF egy széles körben használt metanyelv melynek segítségével szabályok alkothatók meg (például egy programozási nyelv szintaktikai szabályai).Építőkövei:

- ▶  $\langle \text{név} \rangle$ , **fogalmak** (vagy más néven **nemterminálisok**)
- ▶  $::=$ , a szabályok bal- és jobboldalának elválasztászára
- ▶ a sztringek alkotóelemei (**terminálisok**)

Egy szabály bal- és jobboldalból áll, köztük  $::=$ , baloldalon pontosan 1 fogalom, jobboldalon terminálisok és fogalmak véges sorozata állhat.

A BNF megfelel a környezetfüggetlen grammatikának. Példa:

$$\langle \text{azonosító} \rangle ::= \langle \text{betű} \rangle \mid \langle \text{betű} \rangle \langle \text{azvég} \rangle$$
$$\langle \text{azvég} \rangle ::= \langle \text{betű} \rangle \mid \langle \text{számjegy} \rangle \mid \langle \text{betű} \rangle \langle \text{azvég} \rangle \mid \langle \text{számjegy} \rangle \langle \text{azvég} \rangle$$
$$\langle \text{betű} \rangle ::= a \mid \dots \mid z$$
$$\langle \text{számjegy} \rangle ::= 0 \mid \dots \mid 9$$

# Kontrollált környezetfüggetlen grammatikák

BNF-fel nem írható le teljeskörűen a programozási nyelvek szintaxisa (lásd pl. deklaráció fogalma, az  $\{uu \mid u \in V^*\}$  nyelv nem környezetfüggetlen).

Módosítható-e úgy a környezetfüggetlen grammatikák modellje, hogy a természetes, egyszerű szabályalakot megtartsuk, de a modell kifejező ereje nőjön?

Tudnánk-e nem környezetfüggetlen nyelveket generálni környezetfüggetlen grammatikákkal azáltal, hogy például a produkciós szabályok alkalmazhatóságára feltételeket szabunk.

A válasz igen, nézzünk erre néhány példát!

3 példát nézünk, a **programozott grammatikák** és a **mátrixgrammatikák** esetén az alkalmazott szabályok sorrendiségére vonatkozik a kontroll, míg a **véletlen szövegfeltételekkel adott grammatikák** esetében a szabályok alkalmazhatósága az aktuális mondatforma tulajdonságaitól függ.

# Programozott grammatikák

Környezetfüggetlen programozott grammatikán egy  $G = \langle N, T, P, S \rangle$  négyest értünk, ahol

- ▶  $N$  és  $T$  diszjunkt véges ábécék,
- ▶  $S \in N$  a kezdőszimbólum
- ▶  $P$  rendezett hármassok véges halmaza, melyek  $r = (p, \sigma, \phi)$  alakúak, ahol  $p$  egy környezetfüggetlen szabály,  $\sigma, \phi \subseteq P$ .

$\sigma$ -t az  $r$  szabály **siker-halmazának**,  $\phi$  a szabály **kudarc-halmazának** nevezzük.



# Programozott grammatikák

Jelölje  $Q$  a **megengedett** szabályok halmazát. Kezdetben  $Q := P$ .

Egy  $u \in (N \cup T)^*$  mondatformából **egy lépésben levezethető** a  $v \in (N \cup T)^*$  mondatforma, ha van olyan  $r = (A \rightarrow w, \sigma, \phi) \in Q$ , melyre a következők egyike teljesül

- ▶  $u = xAy$  és  $v = xwy$  valamely  $x, y \in (N \cup T)^*$ -ra, ekkor a szabályalkalmazás **sikeres** és  $Q := \sigma$ ,
- ▶  $u$  nem tartalmazza  $A$ -t és  $v = u$ , ekkor a szabályalkalmazás **sikertelen** és  $Q := \phi$ .

Tehát adott mindig megengedett szabályok egy  $Q \subseteq P$  részhalmaza. Választunk egy  $r \in Q$  szabályt. Amennyiben sikerül a kiválasztott szabályt alkalmazni, akkor az adott szabály siker-halmazából, ha nem járunk sikerrel, akkor pedig a kudarc-halmazából kell a következő szabályt választani.

Az így kapott  $\Rightarrow$  reláció reflexív, tranzitív lezártjaként definiáljuk  $\Rightarrow^*$ -t.  $L(G) := \{w \in T^* \mid S \Rightarrow^* w\}$ .

# Programozott grammatikák

Ha  $r = (p, \sigma, \emptyset)$  minden  $r \in P$  szabályra fennáll, akkor a programozott grammatika **előfordulásellenőrzés nélküli**, egyébként **előfordulásellenőrzéses**.

**Példa:** Legyen  $G = \langle \{S, A\}, \{a\}, S, \{r_1, r_2, r_3\} \rangle$ , ahol

$$r_1 = (S \rightarrow AA, \{r_1\}, \{r_2\})$$

$$r_2 = (A \rightarrow S, \{r_2\}, \{r_1, r_3\})$$

$$r_3 = (S \rightarrow a, \{r_3\}, \emptyset)$$

$$\begin{aligned} S &\xRightarrow{r_1} AA \text{ (siker: } \{r_1\} \text{)} \xRightarrow{r_1} AA \text{ (kudarc: } \{r_2\} \text{)} \xRightarrow{r_2} SA \text{ (siker: } \{r_2\} \text{)} \\ &\xRightarrow{r_2} SS \text{ (siker: } \{r_2\} \text{)} \xRightarrow{r_2} SS \text{ (kudarc: } \{r_1, r_3\} \text{)} \xRightarrow{r_3} aS \text{ (siker: } \{r_3\} \text{)} \\ &\xRightarrow{r_3} aa. \end{aligned}$$

Az  $SS$ -en kudarccal végződött  $A \rightarrow S$  átírás után választhattuk volna az  $r_1$  szabályt is, ez újra megduplázta volna az  $S$ -ek számát.

$G$  egy előfordulásellenőrzéses programozott grammatika és  $L(G) = \{a^{2^n} \mid n \geq 0\}$ .

# Mátrixgrammatikák

## Előfordulásellenőrzéses környezetfüggetlen

mátrixgrammatikán egy  $G = \langle N, T, M, S, F \rangle$  ötöst értünk, ahol

- ▶  $N$  és  $T$  diszjunkt véges ábécék,
- ▶  $S \in N$  a kezdőszimbólum,
- ▶  $M = \{m_1, m_2, \dots, m_n\}$ ,  $n \geq 1$ , sorozatok véges halmaza
- ▶  $m_i = (p_{i_1}, \dots, p_{i_{k(i)}})$ ,  $k(i) \geq 1$ ,  $1 \leq i \leq n$ , ahol minden  $p_{ij}$ ,  $1 \leq i \leq n$ ,  $1 \leq j \leq k(i)$ , egy környezetfüggetlen szabály, és
- ▶  $F$   $M$ -beli sorozatok szabályainak egy részhalmaza, azaz  $F \subseteq \{p_{ij} \mid 1 \leq i \leq n, 1 \leq j \leq k(i)\}$ .

$M$  elemeit **mátrixoknak** nevezzük.

Ha  $F = \emptyset$ , akkor a mátrixgrammatikát **előfordulásellenőrzés nélkülinek** nevezzük.

# Mátrixgrammatikák

Legyen  $G = \langle N, T, M, S, F \rangle$  egy tetszőleges mátrixgrammatika.

Ekkor  $u \in (N \cup T)^*$ -ból **egy lépésben levezethető** a

$v \in (N \cup T)^*$  szó az  $m_i = (A_{i_1} \rightarrow v_{i_1}, \dots, A_{i_{k(i)}} \rightarrow v_{i_{k(i)}}) \in M$  mátrix szerint, ha léteznek  $w_1, \dots, w_{k(i)+1} \in (N \cup T)^*$  szavak a következő feltételekkel:

- ▶  $w_1 = u$  és  $w_{k(i)+1} = v$
- ▶ ha  $w_j = x_j A_{i_j} y_j$ , valamely  $x_j, y_j \in (N \cup T)^*$ -ra, akkor  $w_{j+1} = x_j v_{i_j} y_j$  ( $1 \leq j \leq k(i)$ )
- ▶ ha  $A_{i_j}$  nem fordul elő  $w_j$ -ben akkor  $w_{j+1} = w_j$  és  $A_{i_j} \rightarrow v_{i_j} \in F$  ( $1 \leq j \leq k(i)$ )

Jelölés:  $\Rightarrow_{m_i}$  vagy röviden  $\Rightarrow$ ,

$\Rightarrow^*$  (többlépéses levezetés) és  $L(G)$  (generált nyelv) definíciója a szokásos.

# Mátrixgrammatikák

1. Példa:  $u = XYAX$ ,  $v = XYCX$ .

- ▶  $F$  bármi,  $m = (A \rightarrow B, B \rightarrow C)$ , ekkor  $u \Rightarrow v$ ,
- ▶  $F = \emptyset$ ,  $m = (A \rightarrow B, E \rightarrow F, B \rightarrow C)$ , ekkor  $u \not\Rightarrow v$ ,
- ▶  $F \supseteq \{E \rightarrow F\}$ ,  $m = (A \rightarrow B, E \rightarrow F, B \rightarrow C)$ , ekkor  $u \Rightarrow v$ .

2. Példa:

Legyen  $G = \langle N, T, M, S, \emptyset \rangle$  egy mátrixgrammatika előfordulásellenőrzés nélkül, ahol  $N = \{S, A, B\}$ ,  $T = \{a, b\}$ , és  $M = \{m_1, m_2, m_3, m_4, m_5\}$ , ahol

$$m_1 = (S \rightarrow AB),$$

$$m_2 = (A \rightarrow bA, B \rightarrow bB), \quad m_4 = (A \rightarrow aA, B \rightarrow aB),$$

$$m_3 = (A \rightarrow b, B \rightarrow b), \quad m_5 = (A \rightarrow a, B \rightarrow a).$$

$$\begin{aligned} S &\xRightarrow{m_1} AB \xRightarrow{m_4} aAaB \xRightarrow{m_4} aaAaaB \xRightarrow{m_2} aabAaabB \xRightarrow{m_4} \\ &aabaAaabaB \xRightarrow{m_3} aabababab. \end{aligned}$$

Könnyen látható, hogy  $L(G) = \{ww \mid w \in \{a, b\}^+\}$ .

# Véletlen szövegfeltételekkel adott grammatika

Környezetfüggetlen véletlen szövegfeltételekkel adott grammatikán (random context grammar) egy  $G = \langle N, T, P, S \rangle$  négyest értünk, ahol

- ▶  $N$  és  $T$  diszjunkt véges ábécék,
- ▶  $S \in N$  a kezdőszimbólum (axióma),
- ▶  $P$  rendezett hármasok véges halmaza, amelyek  $(p, Q, R)$ , alakúak, ahol  $p$  egy környezetfüggetlen szabály,  $Q, R \subseteq N$ .

elnevezés:  $Q$ -t az  $(p, Q, R)$  hármas **megengedő** (permitting),  $R$ -et pedig **tiltó** (forbidding) kontextusának nevezzük.

# Véletlen szövegfeltételekkel adott grammatika

Egy környezetfüggetlen véletlen szövegfeltételekkel adott grammatika **előfordulásellenőrzés nélküli**, ha minden  $(p, Q, R) \in P$  esetén  $R = \emptyset$ . **Előfordulásellenőrzéses**: amennyiben  $R \neq \emptyset$  is megengedett.

Más elnevezés az előfordulásellenőrzés nélküli esetre: környezetfüggetlen megengedő véletlen szövegfeltételekkel adott grammatika (permitting random context grammar, pRC grammar).

Hasonlóan definálható a környezetfüggetlen tiltó véletlen szövegfeltételekkel adott grammatika (forbidding random context grammar, fRC grammar).

# Véletlen szövegfeltételekkel adott grammatika

Legyen  $G = \langle N, T, P, S \rangle$  egy tetszőleges véletlen szövegfeltételekkel adott grammatika. Ekkor az  $v$  szó **egy lépésben levezethető**  $u$ -ból ( $u, v \in (N \cup T)^*$ ), ha létezik  $(A \rightarrow w, Q, R) \in P$   $x, y \in (N \cup T)^*$ , hogy

- ▶  $u = xAy$  és  $v = xwy$
- ▶ minden  $Q$ -beli nemterminális előfordul  $xy$ -ban
- ▶ semelyik  $R$ -beli nemterminális sem fordul elő  $xy$ -ban

Jelölés:  $\Rightarrow$ .  $\Rightarrow^*$  (többlépéses levezetés) és  $L(G)$  (generált nyelv) definíciója a szokásos.

## Példa:

- ▶ A  $BABaC$  mondatformára az  $(A \rightarrow XY, \{C\}, \{A\})$  szabály alkalmazható, mivel  $C$  van,  $A$  viszont nincs a  $BBaC$  környezetben.  $BABaC \Rightarrow BXYBaC$ .
- ▶ A  $BABaC$  mondatformára az  $(A \rightarrow XY, \{A, B\}, \{X\})$  szabály nem alkalmazható, mert nincs az átírandón felül további  $A$  a szóban, azaz a  $BBaC$  környezetben.



# Véletlen szövegfeltételekkel adott grammatika

**Példa:** Legyen  $G = \langle N, T, P, S \rangle$  egy véletlen szövegfeltételekkel adott grammatika, ahol  $N = \{S, X, Y, A\}$ ,  $T = \{a\}$ , és  $P = \{r_1, r_2, r_3, r_4, r_5\}$ , ahol

$$r_1 = (S \rightarrow XX, \emptyset, \{Y, A\}),$$

$$r_2 = (X \rightarrow Y, \emptyset, \{S\}),$$

$$r_3 = (Y \rightarrow S, \emptyset, \{X\}),$$

$$r_4 = (S \rightarrow A, \emptyset, \{X, Y\}),$$

$$r_5 = (A \rightarrow a, \emptyset, \{S\}).$$

$S \Rightarrow XX \Rightarrow XY \Rightarrow YY \Rightarrow YS \Rightarrow SS \Rightarrow SXX \Rightarrow XXXX \Rightarrow$   
 $XYXX \Rightarrow XYYX \Rightarrow XYYY \Rightarrow YYYY \Rightarrow YYSY \Rightarrow SYSY \Rightarrow$   
 $SSSY \Rightarrow SSSS \Rightarrow SSAS \Rightarrow SSAA \Rightarrow ASAA \Rightarrow AAAA \Rightarrow$   
 $AAAa \Rightarrow aAAa \Rightarrow aaAa \Rightarrow aaaa.$

Végig kényszerpályán a levezetés, egyedül csupa  $S$ -nél van opció, ez mindig 2-hatványnál fordul elő.

Tehát  $L(G) = \{a^{2^n} \mid n \geq 0\}.$

# Nyelvcsaládok, kifejező erő

$\mathcal{L}(\text{PR}_{\text{ac}})$ , illetve  $\mathcal{L}(\text{PR}_{\text{ac}}^\varepsilon)$  jelöli rendre az előfordulásellenőrzéses  $\varepsilon$ -mentes környezetfüggetlen szabályokból, valamint a tetszőleges környezetfüggetlen szabályokból álló programozott grammatikák által generált nyelvek osztályát.

Ha a grammatika előfordulásellenőrzés nélküli, akkor az ac index hiányzik.

Hasonlóképpen:  $\mathcal{L}(\text{MAT}_{\text{ac}})$ ,  $\mathcal{L}(\text{MAT}_{\text{ac}}^\varepsilon)$ ,  $\mathcal{L}(\text{RC}_{\text{ac}})$ , illetve  $\mathcal{L}(\text{RC}_{\text{ac}}^\varepsilon)$ .

## Tétel

Fennállnak a következők

$$\mathcal{L}_2 \subset \mathcal{L}(\text{PR}_{\text{ac}}) = \mathcal{L}(\text{MAT}_{\text{ac}}) = \mathcal{L}(\text{RC}_{\text{ac}}) \subset \mathcal{L}_1$$

és

$$\mathcal{L}(\text{PR}_{\text{ac}}^\varepsilon) = \mathcal{L}(\text{MAT}_{\text{ac}}^\varepsilon) = \mathcal{L}(\text{RC}_{\text{ac}}^\varepsilon) = \mathcal{L}_0.$$

# Nyelvcsaládok, kifejező erő

